

Análisis de Datos de Consultas Externas en Ecuador (2020-2025)

Allen Jahir Mero Chicaiza, Cristopher Paul Balseca Nuñez

Escuela Politécnica Nacional

Quito, Ecuador

allen.mero@epn.edu.ec, cristopher.balseca@epn.edu.ec

Resumen— Este documento presenta el desarrollo integral de un proyecto de análisis de datos centrado en las consultas externas del sistema de salud pública del Ecuador, abarcando el periodo 2020 a 2025. Los datos de los años 2021 a 2024 provienen de fuentes oficiales del Ministerio de Salud Pública, mientras que los datasets correspondientes a 2020 y 2025 fueron generados de forma sintética mediante scripts de Python a partir de los datos reales, con el propósito de evaluar y validar el proceso de limpieza. Se detalla la arquitectura implementada, que abarca la extracción de fuentes de datos públicas, el flujo ETL híbrido utilizando KNIME Analytics Platform y Python, y la visualización y modelado analítico mediante Power BI. El volumen total de datos originales supera los 29 GB, distribuidos en cuatro archivos anuales que fueron muestreados a 450,000 registros por año, limpiados y normalizados para su análisis. Los resultados permiten comprender la distribución geográfica, demográfica y diagnóstica de las atenciones ambulatorias a nivel nacional.

Palabras clave— Análisis de Datos, Consultas Externas, ETL, KNIME, Python, Power BI, Calidad de Datos, CIE-10, Datos Sintéticos.

I. CASO DE ESTUDIO Y OBJETIVOS

A. Caso de Estudio

El proyecto se basa en el análisis de Consultas Externas del sistema de salud pública del Ecuador. La Consulta Externa es un servicio ambulatorio para pacientes con una cita asignada previamente que acceden a atenciones médicas para diferentes tipos de diagnósticos.

La información real analizada corresponde al periodo 2021 hasta el periodo 2024, comprendido en los meses de enero a diciembre. Adicionalmente, se generaron de forma sintética los datasets de los años 2020 y 2025 a partir de los datos reales, introduciendo inconsistencias controladas (valores nulos, espacios extra, problemas de capitalización, duplicados y valores genéricos como "No registra" o "N/A") con el objetivo de disponer de un entorno completo de seis años (2020-2025) que permitiera validar exhaustivamente el pipeline de limpieza ETL.

Este análisis resulta fundamental para comprender las tendencias de salud, la demanda de atención a nivel nacional y los patrones de morbilidad que afectan a la población

ecuatoriana. Los datos contienen información demográfica, geográfica y diagnóstica de cada atención registrada.

B. Objetivos

- Diseñar e implementar una solución integral de análisis de datos para registros médicos ambulatorios del sistema de salud pública, cubriendo el periodo 2020-2025.
- Generar datasets sintéticos con inconsistencias realistas para los años 2020 y 2025, permitiendo evaluar y fortalecer el proceso de limpieza de datos.
- Extraer, limpiar y transformar un gran volumen de información mediante un flujo de trabajo ETL validado, utilizando KNIME Analytics Platform y Python.
- Construir un modelo analítico en Power BI que responda preguntas de negocio mediante dashboards interactivos y medidas DAX.
- Documentar el proceso completo y publicar el proyecto en un repositorio de GitHub como portafolio profesional.

II. ARQUITECTURA DE LA SOLUCIÓN

La arquitectura de datos diseñada contempla cinco capas principales que permiten un flujo de trabajo escalable y reproducible para los seis años de datos analizados:

- Fuentes:** Archivos planos (CSV) de gran tamaño, entre 6 y 8 GB por año para los datos reales (2021-2024), más dos datasets sintéticos generados por Python para 2020 y 2025. Cada archivo contiene 27 columnas de información.
- Procesamiento (ETL):** Se emplearon herramientas de forma conjunta: flujos de KNIME (Muestreo_Consultas_Externas.knwf, Limpieza_Consultas_Externas.knwf) y scripts de Python (Generar_datasets_sucios.ipynb, Normalizacion_CSV_Knime.ipynb).
- Almacenamiento:** Organización local en directorios de staging (Datasets_Muestreo) y directorios finales (Consulta_Externa_Limpiada_PY) para separar datos crudos de datos procesados.

- 4) Visualización: Power BI Desktop para el modelado tabular, creación de relaciones entre tablas, desarrollo de medidas DAX y diseño de dashboards interactivos.
- 5) Documentación y Repositorio: GitHub como sistema de control de versiones y portafolio final del proyecto.



Fig. 1. Arquitectura general de la solución de datos implementada.

III. FUENTES DE DATOS

El proyecto integra seis años de datos de atenciones médicas ambulatorias. Cuatro años provienen de fuentes oficiales del Ministerio de Salud Pública del Ecuador, mientras que dos años fueron generados sintéticamente para completar el rango de análisis y evaluar la robustez del proceso ETL.

A. Datos Reales (2021-2024)

Los archivos originales contienen 27 columnas que incluyen información demográfica (sexo, edad, nacionalidad, autoidentificación étnica), geográfica (zona, provincia, cantón de atención y residencia), diagnóstica (códigos CIE-10 con sus descripciones) y administrativa (tipo de atención, grupos prioritarios, fechas).

- Consulta Externa 2021: Aproximadamente 6.1 GB de registros de atenciones.
- Consulta Externa 2022: Aproximadamente 7.4 GB de registros de atenciones.
- Consulta Externa 2023: Aproximadamente 7.7 GB de registros de atenciones.
- Consulta Externa 2024: Aproximadamente 8.1 GB de registros de atenciones.

Dado el volumen total de más de 29 GB de datos originales, se implementó una estrategia de muestreo aleatorio mediante KNIME para extraer subconjuntos representativos de 450,000 registros por año, permitiendo el procesamiento local sin exceder los límites de memoria.

B. Datos Sintéticos Generados (2020 y 2025)

Mediante el notebook Generar_datasets_sucios.ipynb se crearon dos datasets ficticios de 450,000 registros cada uno. El dataset de 2020 fue derivado combinando 225,000 registros aleatorios de 2021 y 225,000 de 2022, ajustando las fechas de atención al año 2020 y recalculando las edades. El dataset de 2025 se construyó de forma análoga a partir de 2023 y 2024.

A ambos datasets se les inyectaron inconsistencias controladas con los siguientes porcentajes aproximados:

- Valores nulos en columnas de texto secundarias (~2.5% de celdas, ~675,000 celdas por dataset).
- Espacios en blanco al inicio o final del texto (~2%, ~269,000 valores).
- Capitalización inconsistente: mayúsculas/minúsculas mixtas (~2%, ~220,000 valores).
- Valores de reemplazo genéricos: "No registra", "N/A", "-", "" (~2%, ~214,000 celdas).
- Duplicados parciales insertados in-place (~1.5%, 6,750 filas por dataset).

En total, aproximadamente el 11% de las celdas de cada dataset sintético fueron modificadas, generando un entorno realista para la validación del proceso de limpieza. Los archivos resultantes fueron: Consulta_Externa_2020_Muestra_Sucio.csv y Consulta_Externa_2025_Muestra_Sucio.csv.

IV. PROCESO ETL Y CALIDAD DE DATOS

El proceso de Extracción, Transformación y Carga (ETL) y el aseguramiento de la calidad se dividió en cuatro fases clave, alternando las fortalezas de KNIME y Python para lograr una limpieza exhaustiva y reproducible sobre los seis años de datos.

A. Muestreo (KNIME)

A través del flujo de trabajo Muestreo_Consultas_Externas.knwf se extrajeron subconjuntos manejables de 450,000 registros por año de los datos reales (2021-2024). Este paso fue crítico para evitar cuellos de botella en la memoria, ya que los archivos originales superaban los 6 GB individualmente. El muestreo se realizó de forma aleatoria para mantener la representatividad estadística de los datos originales.




Fig. 2. Flujo de trabajo en KNIME para el muestreo aleatorio de registros reales.

B. Generación de Datasets Sintéticos (Python)

Se utilizó el notebook Generar_datasets_sucios.ipynb para crear los datasets de 2020 y 2025 a partir de los datos muestreados. El proceso consistió en tres etapas: (1)

combinación de registros de dos años base para generar 450,000 registros, (2) ajuste de fechas de atención y recálculo de edades al año destino, y (3) inyección de cinco tipos de inconsistencias con porcentajes controlados, totalizando aproximadamente 1,370,000 a 1,392,000 celdas modificadas por dataset (~11% del total).



Fig. 3. Notebook en Python para la generación de datasets sintéticos con inconsistencias.

C. Limpieza Principal (KNIME)

El flujo de trabajo Limpieza_Consultas_Externas.knwf procesó los seis datasets (2020-2025), encargándose de las transformaciones estructurales principales: estandarización de nombres de columnas, filtrado de registros atípicos (outliers), eliminación de filas duplicadas, tratamiento de valores nulos y combinación de tablas. KNIME permitió visualizar cada paso del pipeline de forma gráfica, facilitando la auditoría del proceso.




Fig. 4. Flujo de trabajo en KNIME para la consolidación y limpieza principal de datos.

D. Normalización Avanzada (Python)

Con el notebook Normalizacion_CSV_Knime.ipynb se realizó una corrección de calidad de datos a nivel de detalle que complementa lo realizado en KNIME:

- Corrección de encoding: Conversión de UTF-8-SIG (BOM) a UTF-8 estándar.
- Eliminación de caracteres no ASCII y tildes mediante normalización Unicode (descomposición NFD y remoción de marcas diacríticas).
- Estandarización de formatos de fecha al estándar ISO yyyy-mm-dd, soportando múltiples formatos de entrada (dd/mm/yyyy, dd-mm-yyyy, yyyy/mm/dd).
- Eliminación de espacios redundantes en campos de texto.
- Corrección de datos sucios residuales: "NEGRO /A" corregido a "NEGRO/A" y "AFROECUATORIANO/AFRODESCENDIENTEFR ODESCENDIENTE" corregido a "AFROECUATORIANO/AFRODESCENDIENTE".



Fig. 5. Notebook en Python para la normalización avanzada y corrección de calidad.

V. MODELO DE DATOS Y ANÁLISIS EN POWER BI

Una vez completado el proceso ETL sobre los seis años de datos (2020-2025), los datasets limpios fueron cargados en Power BI Desktop para la construcción del modelo analítico.




Fig. 6. Modelo relacional de datos construido en Power BI Desktop.

A. Esquema del Modelo

Se implementó un esquema en estrella, conformado por la tabla de hechos Fact_Atenciones, que almacena los registros de las atenciones, y las dimensiones Dim_Calendario (información temporal) y Fact_Diagnósticos (clasificación de diagnósticos). Además, se emplea la tabla Consulta_Externa_Muestra como fuente de información descriptiva de los pacientes y una tabla de Medidas para centralizar los cálculos en DAX. Esta estructura optimiza el rendimiento del modelo, facilita el análisis multidimensional y mejora la organización de los datos en Power BI.

B. Medidas DAX Principales

1. Total de Atenciones (KPI Principal de Volumen)

Mide el número de pacientes atendidos (citas médicas). Como un paciente puede tener varios diagnósticos, contamos las filas de la tabla principal de atenciones.

```
Total Atenciones =
COUNTROWS('Fact_Atenciones')
```

2. Total de Diagnósticos Tratados

Mide el volumen de enfermedades tratadas, contando las filas de la tabla que desdoblamos (donde filtramos los "NO APLICA").

```
Total Diagnósticos =
COUNTROWS('Fact_Diagnosticos')
```

3. Promedio de Diagnósticos por Atención

Nos dice qué tan complejos son los cuadros clínicos (ej. si el promedio es cercano a 3, los pacientes llegan con múltiples patologías).

```
Promedio Diag por Atencion =
DIVIDE([Total Diagnósticos], [Total
Atenciones], 0)
```

4. Atenciones del Mes Anterior (MoM - Tendencia)

Calcula cuántas atenciones hubo exactamente un mes atrás respecto a la selección actual. Requiere que Dim_Calendario esté conectada.

```
Atenciones Mes Anterior =
CALCULATE(
    [Total Atenciones],
    DATEADD('Dim_Calendario'[Date], -1,
MONTH)
)
```

5. Variación Porcentual Mensual (MoM %)

El KPI vital para saber si la demanda en los hospitales sube o baja respecto al mes pasado.

```
% Var Atenciones Mes =
DIVIDE(
    [Total Atenciones] - [Atenciones
Mes Anterior],
    [Atenciones Mes Anterior],
    0
)
```

6. Atenciones Acumuladas en el Año (YTD)

Muestra cómo va creciendo el volumen de pacientes desde el 1 de enero hasta la fecha seleccionada.

```
Atenciones YTD =
TOTALYTD(
    [Total Atenciones],
    'Dim_Calendario'[Date]
)
```

7. Ranking de Provincias (Carga Operativa)

Enumera a las provincias desde la que atiende a más pacientes (1) hasta la que atiende a menos, independientemente de los filtros.

```
Ranking Provincias =
IF(
    ISBLANK([Total Atenciones]),
    BLANK(),
    RANKX(
        ALL('Fact_Atenciones'[PROVINCIA]),
        [Total Atenciones],
        ,
        DESC,
        Dense
    )
)
```

8. Porcentaje de Atenciones Preventivas (Morbilidad vs. Prevención)

Calcula qué proporción del esfuerzo médico se destina a la prevención de enfermedades en lugar de curarlas.

(Asumiendo que la columna se llama TIPO_ATENCION en Fact_Diagnosticos).

```
% Atenciones Prevención =
VAR Prevencion = CALCULATE(
    [Total Diagnósticos],
    'Fact_Diagnosticos'[TIPO_ATENCION]
= "Prevención"
)
RETURN
DIVIDE(Prevencion, [Total
Diagnósticos], 0)
```

VI. VISUALIZACIONES Y RESULTADOS

Se diseñaron cuatro páginas de dashboard en Power BI para responder a las preguntas analíticas del proyecto, cubriendo los seis años del periodo 2020-2025.

A. Dashboard 1: Resumen Ejecutivo




Fig. 7. Dashboard 1: Resumen Ejecutivo y Análisis Geográfico.

La página de Resumen Ejecutivo ofrece una visión integral del comportamiento del sistema de salud, presentando indicadores clave como el volumen total de atenciones y diagnósticos, la evolución mensual de la demanda y la distribución geográfica de la carga asistencial por provincias y zonas. Esta perspectiva permite comprender rápidamente el estado operativo del sistema, identificar tendencias de crecimiento o disminución en la demanda y localizar las áreas con mayor presión sobre los servicios de salud. A partir de esta información, los directivos pueden respaldar la toma de decisiones estratégicas relacionadas con la asignación de presupuesto, la distribución de recursos entre territorios y la planificación anticipada de la capacidad operativa frente a futuros incrementos en la demanda.

B. Dashboard 2: Exploración Demográfica




Fig. 8. Dashboard 2: Exploración Demográfica por edad, sexo y etnia.

La página de Exploración Demográfica analiza el perfil de la población atendida mediante variables como edad, sexo, autoidentificación étnica y distribución territorial de los pacientes a lo largo del tiempo. Este análisis permite identificar los grupos poblacionales que requieren mayor atención, detectar posibles desigualdades en el acceso a los servicios de salud y reconocer la concentración de poblaciones prioritarias, como niños y adultos mayores. Con esta información es posible diseñar políticas públicas y programas preventivos más focalizados, orientar la asignación de recursos hacia las necesidades específicas de cada territorio y garantizar que la prestación de los servicios responda de manera adecuada a la diversidad cultural y demográfica de la población.

C. Dashboard 3: Análisis de Diagnósticos




Fig. 9. Dashboard 3: Análisis de Diagnósticos y morbilidad CIE-10.

La página de Análisis de Diagnósticos presenta la carga de morbilidad mediante el estudio de las enfermedades más frecuentes, su agrupación por categorías diagnósticas y su relación con las distintas especialidades médicas a lo largo del tiempo. Este análisis permite comprender cuáles son las patologías que generan la mayor demanda de atención y consumen una proporción significativa de recursos humanos, medicamentos e insumos médicos. La información obtenida facilita la optimización de la

planificación sanitaria, apoyando decisiones relacionadas con el abastecimiento estratégico de medicamentos, la contratación o redistribución de especialistas y la actualización de protocolos clínicos enfocados en las enfermedades con mayor impacto sobre el sistema de salud.

D. Dashboard 4: Detalle Operativo



Fig. 10. Dashboard 4: Detalle Operativo y variaciones mensuales de la demanda.

La página de Detalle Operativo ofrece el nivel más específico del análisis, desagregando el volumen de atenciones por zonas, provincias, cantones y tipos de atención, además de mostrar las variaciones mensuales con precisión numérica. Esta información permite trasladar la visión estratégica nacional al contexto local, identificando diferencias de desempeño, posibles cuellos de botella y variaciones significativas que podrían pasar desapercibidas en análisis agregados. Gracias a este nivel de detalle, los responsables de la gestión territorial pueden implementar acciones correctivas oportunas, evaluar el desempeño de las unidades de salud, investigar las causas de disminuciones en la actividad operativa y redistribuir recursos o carga asistencial para mejorar la eficiencia y la calidad de los servicios prestados.

VII. CONCLUSIONES Y RECOMENDACIONES

A. Conclusiones

La combinación de KNIME Analytics Platform y Python demostró ser una estrategia altamente eficiente para manejar grandes volúmenes de datos donde herramientas tradicionales como Microsoft Excel resultan insuficientes. El proceso de normalización de texto representó el desafío técnico más significativo debido a la presencia de caracteres especiales, tildes corruptas y múltiples formatos de fecha en los datos de origen.

La generación de datasets sintéticos para 2020 y 2025 demostró ser una estrategia valiosa para validar el pipeline ETL, ya que permitió verificar que el flujo de limpieza detectara y corrigiera correctamente los cinco tipos de inconsistencias inyectadas (valores nulos, espacios, capitalización, valores genéricos y duplicados), abarcando aproximadamente el 11% de las celdas en cada dataset.

El análisis visual mediante Power BI permitió identificar una marcada estacionalidad en la demanda de consultas externas, con picos recurrentes en los meses de marzo y octubre. Además, se evidenció que la mayor carga asistencial recae sobre la población femenina en edad reproductiva, y que los controles de salud de rutina y la hipertensión esencial lideran las causas de atención, lo que subraya la importancia de fortalecer la atención primaria y preventiva.

B. Recomendaciones

- Implementar controles de calidad y validación de datos desde el origen (sistemas hospitalarios) para estandarizar el ingreso de fechas y textos, reduciendo así la necesidad de transformaciones complejas en la etapa ETL.
- Focalizar recursos y campañas de prevención en las zonas y cantones de mayor demanda identificados, así como desarrollar programas de salud preventivos específicos para mujeres entre 20 y 40 años.
- Fortalecer la capacitación del personal de salud en el correcto registro de diagnósticos CIE-10 para minimizar el uso de códigos genéricos, mejorando así la precisión de los análisis epidemiológicos.

VIII. PROBLEMAS ENCONTRADOS Y TRABAJO FUTURO

A. Problemas Encontrados

- **Problema 1.** Desbordamiento de memoria: El tamaño original de los datasets (hasta 8 GB por archivo) provocaba errores de "Out of Memory" tanto en pandas como en KNIME al intentar cargar los archivos completos. Solución: Implementación de muestreo aleatorio previo mediante KNIME para reducir el volumen a 450,000 registros por año.
- **Problema 2.** Inconsistencias de formato: Los datos presentaban fechas en múltiples formatos (dd/mm/yyyy, yyyy-mm-dd, dd-mm-yyyy), diferencias de capitalización en nombres de provincias y cantones, y caracteres especiales corruptos por problemas de encoding. Solución: Desarrollo de funciones personalizadas en Python utilizando las librerías unicodedata y pandas para normalización automatizada.
- **Problema 3.** Generación de datos sintéticos consistentes: Al crear los datasets de 2020 y 2025, fue necesario ajustar las fechas de atención al año destino y recalcular las edades de los pacientes para mantener la coherencia interna del dataset, considerando múltiples formatos de fecha de nacimiento.

B. Trabajo Futuro

Como trabajo futuro, se propone migrar la arquitectura actual a un entorno en la nube (como AWS o Azure) para automatizar el flujo ETL y la actualización de los

dashboards. Además, se sugiere incorporar técnicas de Machine Learning para predecir picos de demanda en consultas externas basándose en datos históricos, lo cual facilitaría la asignación proactiva de recursos médicos.

REFERENCIAS

- [1] Ministerio de Salud Pública del Ecuador, "Datos Abiertos de Consultas Externas," Portal de Datos Abiertos, 2024.
- [2] KNIME AG, "KNIME Analytics Platform," <https://www.knime.com/>, 2024.
- [3] W. McKinney, "pandas: a Foundational Python Library for Data Analysis and Statistics," Python for High Performance Scientific Computing, 2011.
- [4] Microsoft, "Power BI Desktop," <https://powerbi.microsoft.com/>, 2024.
- [5] Organización Mundial de la Salud, "Clasificación Internacional de Enfermedades CIE-10," WHO, 2019.
- [6] NumPy Developers, "NumPy: The fundamental package for scientific computing with Python," <https://numpy.org/>, 2024.
- [7] [Agregar más referencias según sea necesario.]

Repositorio del Proyecto:

<https://github.com/AllenMero914/ProyectoAnálisisDato>

S